

Criptanaliza cifrului Speck32/64 utilizând rețele neuronale convoluționale

Lepădatu Teodor

Universitatea din București
Facultatea de Matematică și Informatică
Specializarea Informatică

Coordonator științific: Lect. dr. Bucataru Mihai

București, Iulie 2026

Dezvoltarea sistemelor cu resurse limitate a condus, prin nevoia de a fi protejate, la apariția unor algoritmi criptografici proiectați special pentru a funcționa eficient în condiții stricte de memorie și putere de calcul. Astfel de cazuri includ rețelele de senzori și dispozitivele integrate.

Un exemplu de astfel de algoritm este *Speck*, al cărei variantă *Speck32/64* este analizată în această lucrare.

Descrierea algoritmului de criptare Speck32/64

Speck este un cifru bloc de tip ARX (Addition, Rotation, XOR) care are următorii parametri:

- **dimensiunea cuvântului** = 16 biți
- **bloc** = (L, R) = cuvântul criptat (care are 32 de biți) este împărțit în două subcuvinte de 16 biți
- **cheie** = număr pe 64 de biți
- **rotații** = numărul de biți roțiți la dreapta sau la stânga în funcția de criptare (valorile folosite sunt $\alpha = 7$ pentru rotația dreapta pe L și $\beta = 2$ pentru rotația stânga pe R)
- **număr de runde** = numărul de subchei în care este împărțită cheia inițială

Descrierea algoritmului de criptare Speck32/64

Facem următoarele notații:

- $ROR(L, \alpha)$ rotația la dreapta în L cu α biți
- $ROL(R, \beta)$ rotația la stânga în R cu β biți
- K subcheia runde curente, derivată din cheia inițială, având lungimea exactă de w biți
- $\oplus$ operația XOR pe biți

Pentru **criptarea** mesajului folosim:

$$f_K(L, R) = (L', R')$$

unde:

$$L' = ((ROR(L, \alpha) + R) \bmod 2^w) \oplus K$$

$$R' = ROL(R, \beta) \oplus L'$$

Pentru **decriptare** folosim inversa f_K :

$$f_K^{-1}(L', R') = (L, R)$$

unde:

$$R = ROR(R' \oplus L', \beta)$$

$$L = ROL(((L' \oplus K) - R) \bmod 2^w, \alpha)$$

Definirea problemei de atac și generarea datelor

- **Definirea problemei:** Construirea unui *neural distinguisher* bazat pe o rețea neuronală convoluțională (CNN) care evaluează o pereche de texte cifrate (C_1, C_2) și returnează o probabilitate $p \in [0, 1]$. Aceasta răspunde dacă perechea provine din criptarea a două texte clare ce respectă o diferență XOR fixă $(\Delta P = (\Delta L, \Delta R))$.
- **Generarea datelor de antrenare pentru rețea:**
 - **Exemple pozitive (reale):** Obținute prin criptarea perechilor clare: (L, R) și $(L \oplus \Delta L, R \oplus \Delta R) \rightarrow (C_1, C_2)$.
 - **Exemple negative (aleatoare):** Al doilea text cifrat C_2 este înlocuit cu o valoare generată uniform aleator.
 - Setul total de date este perfect echilibrat (50% pozitive, 50% negative).

- **Turnul rezidual:** Integrează un număr variabil de blocuri reziduale (*depth*):
 - Conv1d (extindere $3 \rightarrow 32$ canale, $\text{kernel}=3$, $\text{padding}=1$), BatchNorm1d, ReLU.
 - Conv1d (contractare $32 \rightarrow 3$ canale, $\text{kernel}=3$, $\text{padding}=1$), BatchNorm1d, ReLU.
 - Conexiune reziduală (adunarea intrării originale pentru a preveni vanishing gradient).
- **Prediction head:** Aplatizare vector la 48 elemente $\rightarrow$ două straturi Linear (64 neuroni) cu BatchNorm1d și ReLU $\rightarrow$ strat Linear (1 neuron) cu activare Sigmoid.
- **Parametri de antrenare:** Funcție de pierdere MSELoss, optimizator Adam (weight decay 10^{-5}), planificator OneCycleLR (LR max 10^{-3}), loturi de 5000 de exemple.

- Antrenarea s-a realizat pe un set de 10^7 eșantioane ($9 \cdot 10^6$ antrenare, 10^6 validare) folosind configurații specifice de adâncime și durată pentru numărul de runde analizat.

Tabela: Acuratețea modelului pe setul de validare

Model	Acuratețe (%)
5 runde (<i>depth</i> = 10, 200 epoci)	92.74
6 runde (<i>depth</i> = 10, 200 epoci)	78.79
7 runde (<i>depth</i> = 1, 300 epoci)	55.14
8 runde (<i>depth</i> = 1, 300 epoci)	≈ 50.00

- Adversarul interceptează texte cifrate generate sub aceeași cheie secretă, fără a cunoaște textul clar sau cheia.
- Obiectivul adversarului este recuperarea ultimei subchei folosite în procesul de criptare al ultimei runde. Orice metrică de evaluare prezentată va lua în considerare doar acest obiectiv setat.
- Odată determinată ultima subcheie, datele sunt decriptate parțial o rundă înapoi, iar algoritmul de criptanaliză se repetă recursiv până la recuperarea întregului material.
- *Neural distinguisher*-ul antrenat pentru $n - 1$ runde este alimentat cu date parțial decriptate cu o cheie candidată pentru a evalua corectitudinea acesteia.

Metoda Sum of Logits (SoL) și rezultate

Presupunem că dispunem de n perechi de texte cifrate $(C_{i1}, C_{i2}), i = \overline{1, n}$, obținute dintr-o structură, și cunoaștem lungimea ultimei subchei. Pentru fiecare cheie candidată K din spațiul de chei aferent, decriptăm parțial cele n perechi. CNN-ul evaluează fiecare rezultat, oferind o probabilitate $p_i(K)$. Valoarea maximă a scorului $S(K)$ va indica subcheia cea mai probabilă.

$$S(K) = \sum_{i=1}^n \log_2 \left(\frac{p_i(K)}{1 - p_i(K)} \right)$$

Tabela: Performanța atacului Sum of Logits (Top 32)

Atac	Rată de succes (%)	Loc mediu cheie reală
6 runde	100.0	1.50
7 runde	100.0	1.60
8 runde	100.0	5.10

- **WKRP (Wrong Key Response Profile)** reprezintă un profil precalculat al răspunsului rețelei neuronale pentru chei greșite.
- **Mod de calcul:**
 - Se evaluează textele cifrate decriptate parțial pentru diverse diferențe dintre cheia reală și cea de test ($\Delta k = k_i \oplus k$).
 - Rezultatele sunt transformate în *log-odds* pentru a extrage **media** ($\mu_{\Delta k}$) și **deviația standard** ($\sigma_{\Delta k}$) aferente fiecărei diferențe.
- Generarea profilului este o operație costisitoare, necesitând evaluarea a milioane de perechi pentru toate cele $2^{16} = 65536$ de diferențe posibile.

Bayesian Key Search (BKS) și rezultate

Deoarece ipoteza randomizării eșuează pentru chei greșite, dar apropiate de cea reală, metoda se folosește de profilele **WGRP** precalculate (μ, σ) .

Mecanismul algoritmului iterativ:

-  **Evaluarea empirică:** Se pornește cu un set de n_{cand} chei (reținând forțat optimul global). Se obține scorul mediu log-odds (m_{k_i}) pentru fiecare, utilizând decriptări parțiale (o rundă) și evaluări CNN.
-  **Scorul de penalizare:** Se parcurge tot spațiul de chei posibile $(k \in \mathcal{K})$. Pentru fiecare, se calculează distanța $\lambda(k)$ comparând mediile observate (m_{k_i}) cu cele așteptate teoretic din WGRP $(\mu_{k_i \oplus k})$.
-  **Actualizarea:** Se păstrează cele n_{cand} chei care obțin cel mai mic scor $\lambda(k)$ (penalizare minimă) și se reia iterația.

Distanța euclidiană ponderată:

$$\lambda(k) = \sum_{i=0}^{n_{cand}-1} \frac{(m_{k_i} - \mu_{k_i \oplus k})^2}{\sigma_{k_i \oplus k}^2}$$

Tabela: Performanța BKS (Top 32)

Atac	Succes (%)	Loc mediu
6 runde	100.0	1.00
7 runde	100.0	1.00
8 runde	20.0	2.50

Fine-tuning cu exemple negative dificile

- **Problema identificată:** La atacul practic, decriptările parțiale cu o cheie greșită nu produc date perfect uniforme, ci păstrează corelații structurale specifice algoritmului, slăbind distincția CNN-ului standard.
- **Hard Negative Mining (Generarea de exemple negative fidele scenariului de inferență):** Se criptează datele pe R runde cu cheia corectă, se mai criptează o rundă corect, iar apoi se decriptează o rundă folosind o subcheie aleatorie, astfel imitând cel mai comun scenariu întâlnit în practică.
- Modelele standard au fost supuse unui proces de fine-tuning pentru încă 20 de epoci pe aceste seturi de date specifice.
- **Rezultat:** Acuratețea modelului pe perechi de tip negativ dificil a crescut cu aproximativ 1%, eliminând unele răspunsuri fals-pozitive.

- **Problema identificată:** Construirea profilului de distribuții WKRP cere evaluarea a milioane de perechi de texte pentru absolut toate cele $2^{16} = 65536$ de diferențe posibile de cheie, fiind o operație extrem de costisitoare computațional.
- **Soluția de caching offline:** Deoarece tabelele rămân identice pentru același model și număr de runde, profilele (μ și σ) sunt calculate o singură dată și serializate pe disc sub formă de fișiere.
- **Avantajul fazei de atac:** În timpul execuției atacului, profilele sunt încărcate direct în memoria VRAM, eliminând complet recalcularea.

Metodele hibride propuse

Pentru combinarea avantajelor filtrelor rapide și preciziei bayesiene, au fost implementate 6 configurări:

- **M1 (Original BKS):** Algoritmul BKS standard utilizând modelul antrenat tradițional.
- **M2 (Fine-Tuned BKS):** Algoritmul BKS aplicat pe spațiul complet de chei folosind exclusiv modelul ajustat fin (FT).
- **M3 (SoL → Original BKS):** Filtrare inițială ultrarapidă a unui top de 64 de candidați prin tehnica SoL, urmată de evaluarea exclusivă a acestora prin BKS original.
- **M4 (SoL → Fine-Tuned BKS):** Filtrare rapidă a 64 de chei prin SoL, urmată de analiza fină prin BKS cu modelul FT.
- **M5 (Ensemble BKS):** Evaluare BKS în care decizia rețelei este un ansamblu ponderat al modelelor standard și FT, bazat pe inversul pătratelor pierderilor de validare ($p_{final} = \alpha_1 p_{base} + \alpha_2 p_{FT}$).
- **M6 (SoL → Ensemble BKS):** Filtrare completă a spațiului prin SoL la 64 de chei, rafinate ulterior prin tehnica Ensemble BKS.

Tabela: Rezultate atac 6 runde (DND 5r)

Metrică	M1	M2	M3	M4	M5	M6
Acuratețe (%)	90.0	100.0	100.0	100.0	100.0	100.0
Timp Mediu (s)	0.54	0.52	257.65	155.67	1.06	232.06

Tabela: Rezultate atac 7 runde (DND 6r)

Metrică	M1	M2	M3	M4	M5	M6
Acuratețe (%)	90.0	100.0	100.0	100.0	100.0	100.0
Timp Mediu (s)	0.78	0.77	342.34	261.34	1.52	321.23

Tabela: Rezultate atac 8 runde (DND 7r)

Metrică	M1	M2	M3	M4	M5	M6
Acuratețe (%)	0.0	0.0	20.0	20.0	0.0	20.0
Timp Mediu (s)	0.75	0.72	305.51	242.12	1.48	255.42

● Concluzii:

- Fine-tuning-ul bazat pe exemple negative dificile este critic pentru eliminarea corelațiilor reziduale și a alarmelor fals-pozitive.
- Optimizarea prin caching offline aduce o reducere drastică a timpului de atac pentru căutarea bayesiană.
- Algoritmii hibridi propuși reprezintă un compromis ideal între viteză și acuratețe, devenind singura soluție viabilă în scenariul complex de 8 runde.

● Direcții viitoare de cercetare:

- **Transfer Learning / Curriculum Learning:** Utilizarea unui model pre-antrenat pe un număr mai mic de runde (ex. 7 runde) ca profesor pentru ghidarea modelelor de ordin superior.
- **Arhitecturi moderne:** Explorarea rețelelor bazate pe mecanisme de atenție (*Transformers*) pentru a capta dependențele neliniare globale dintre biți, depășind limitele locale convoluționale.
- **Generalizare:** Extinderea tehnicilor și a caching-ului WKRP pe alte cifruri lightweight (Simon, ChaCha20, Simeck).

Vă mulțumesc pentru atenție!

Q&A?

Codul sursă și mediul de evaluare:

https://github.com/TeodorLepadatu/Bachelor_thesis

Lucrările de referință importante:

- Beaulieu, R. et al. (2013). *The SIMON and SPECK Families of Lightweight Block Ciphers*. <https://eprint.iacr.org/2013/404>
- Gohr, A. (2019). *Improving Attacks on Round-Reduced Speck32/64 using Deep Learning*. <https://eprint.iacr.org/2019/037>
- Zheng, W., Zhang, L., & Wang, Z. (2024). *On the Explanation and Enhancement of Neural-inspired Differential Cryptanalysis*. <https://api.semanticscholar.org/CorpusID:281400354>